





іТМО

Машинное обучение для рекомендательных систем

Вспоминаем, что такое ML


С точки зрения задачи



Вспоминаем, что такое ML

С точки зрения процесса



The background features a dark, almost black, grid pattern. Overlaid on this grid are several wavy, glowing purple lines that create a sense of movement and depth. These lines are more prominent in the corners and fade towards the center.

іТМО

Данные

Концептуально

Items

Users

						
	10	-1	8	10	9	4
	8	9	10	-1	-1	8
	10	5	4	9	-1	-1
	9	10	-1	-1	-1	3
	6	-1	-1	-1	8	10

➔ User-item Interaction matrix

— ×


Айтемы (единицы контента)

Items, I. Минимальный объект, который система может рекомендовать пользователю



Признаки айтемов:

- Числовые – цена, рейтинг, количество покупок/просмотров, год выпуска
- Категориальные – жанр, автор/исполнитель, издательство, страна производства, возрастной рейтинг
- Структурные (служебные) – формат, размер файла
- Мультимодальные – текст, изображение, видео, аудио



Юзеры (пользователи)

Users, U. Динамическая сущность, чей профиль постоянно обновляется

Атрибуты пользователей:

- Статические – пол, возраст, страна, язык, образование, профессия, семейное положение
- Динамические – история действий в сервисе, время на странице, глубина скролла
- Вычисляемые – предпочтительные жанры и категории, средний чек, уровень вовлечённости



Интеракции (взаимодействия)


Interactions / ratings, R . Запись факта взаимодействия пользователя и контента в **определённый момент времени** (событие в логах)

Фидбэк:

- Явный (explicit) – лайк, дизлайк
- Неявный (implicit) – просмотр

Процент прослушивания – ?

Просмотры еще называют impression-ами



(a) Bipartite diagram of user-item interaction

	Item						
	0	1	2	3	4	5	6
0	1	0	0	0	0	0	1
1	0	1	0	1	0	0	0
2	1	0	1	0	0	0	1
3	0	0	0	1	0	1	0
4	0	1	1	0	0	1	1

(b) User-item matrix(R)

Логи. Истории из практики

іТМО

- 30% потерянных логов по причине словаря где-то в недрах кода
- 110% просмотра видео
- Шпинат за 450к (я надеюсь, речь шла о шпинатной плантации)
- Дубликаты на каждое событие (ms != ns)
- Цена во float
- 7к просмотров товаров за день одним аккаунтом

		китайский	176
		испанский	61
		общество	43
		литература	40
		обществознание	23
		английский	23
		искусство	10
		итальянский	8
		китайский	6
#	referer ▲		
2			
3	" "		
4	NULL		
5			
6			
7			
8			
9	"None"		

Датасеты и бенчмарки

Dataset category	Representative datasets	Typical applications	Typical evaluation outcomes
Movie recommendation datasets	MovieLens, Netflix, MovieTweatings	Collaborative filtering, rating prediction, top- n recommendation	Prediction accuracy, ranking quality, benchmark comparison
E-commerce datasets	Amazon, RetailRocket, Yelp	Hybrid recommendation, purchase prediction, review-aware recommendation	Ranking performance, implicit-feedback evaluation, commercial relevance
Music and media datasets	Last FM, Spotify Million Playlist, Spotify skip prediction	Sequential recommendation, playlist continuation, implicit-feedback recommendation	Session-based accuracy, next-item prediction, user behaviour modeling
News datasets	MIND, EB-NeRD	Time-aware recommendation, dynamic ranking, user-interest tracking	Temporal evaluation, short-term relevance, freshness-aware recommendation
Academic datasets	DBLP, CiteULike	Paper recommendation, citation-aware recommendation, scholarly retrieval support	Relevance ranking, personalized retrieval, domain-specific recommendation
Social and trust-based datasets	Epinions, FilmTrust, Ciao DVD, Gowalla	Trust-aware recommendation, social recommendation, location-aware recommendation	Social influence analysis, trust-based ranking, context-sensitive evaluation
Challenge datasets	Twitter, Dressipi, ShareChat, Synerise	Fairness-aware recommendation, session-based recommendation, privacy-aware advertising, multi-task modeling	Fairness evaluation, session accuracy, industrial benchmarking, multi-task performance



Dataset	Main property	Research challenge	Typical methodological response
MovieLens	Explicit feedback, benchmark dataset	Limited coverage of real-world implicit behaviour	Collaborative filtering, matrix factorization, rating-prediction models
Netflix	Large-scale explicit ratings	Sparsity despite large scale	Matrix factorization, ensemble methods
Amazon	Large-scale reviews and metadata	High item diversity and sparse interactions	Hybrid methods, review-aware models, knowledge-aware recommendation
RetailRocket	Implicit feedback, click/purchase events	Noisy behavioural signals and session variation	Session-based and implicit-feedback recommendation methods
MIND	Temporal news interactions	Rapidly changing user interests and short item lifespan	Sequential, time-aware, and news recommendation models

Индустриальные датасеты



Dataset	Domain	Scale	Key Characteristics	Primary Research Focus
Amazon Reviews 2023	E-commerce	571M interactions	Multi-category reviews with product metadata	Ranking, sentiment analysis, long-tail discovery
RecFlow	Short Video	1.9B samples	Full-funnel recommendation logs	Pipeline optimization, debiasing
Criteo 1TB	Advertising	4B interactions	Categorical and numerical ad log features	CTR prediction, large-scale classification
Yambda-5B	Music	4.79B interactions	Organic vs. recommended plays, audio embeddings	Bias analysis, causal recommendation
VK-LSVD	Short Video	40B interactions	Implicit and explicit engagement signals	Sequential modeling, long-term preferences
T-ECD	E-commerce	135B interactions	Cross-domain banking super-app data	Cross-domain learning, long-term multi-behavior modeling

іТМО

Машинное обучение для рекомендательных систем

Каскадное проектирование в ML

Бизнес метрики -> онлайн-метрики (прокси между бизнесом и ML) -> офлайн-метрики (подо что можем оптимизироваться) -> лосс-функция (то, как именно оптимизируемся)



Пусть мы хотим улучшить полку похожих товаров, тогда:

Уровень	Метрика	Описание	Роль
Бизнес	GMV с полки	Доп. выручка от блока	Цель. То, ради чего всё затеяно
Online	CTR на полке	Доля кликов по блоку относительно его показов	Прокси для GMV. Коррелирует с выручкой
Offline	Recall@5	Доля релевантных товаров, попавших в топ-5 выдачи	Прокси для CTR. Коррелирует с кликабельностью
Loss	BCE	Бинарная классификация: похож / не похож	Прокси для Recall. Оптимизируем во время обучения

Типичная (но не единственная) постановка задачи рекомендаций

ITMO



Цель: Обучить функцию скоринга:

$$\hat{f} : U \times I \rightarrow \mathbb{R}$$

где $\hat{f}(u, i)$ — релевантность предмета i для пользователя u (чем больше, тем лучше)

А что есть релевантность
— вопрос хороший 😊

Результат: Для каждого пользователя u список Top- N рекомендаций:

$$\text{Top-}N(u) = \arg \max_{S \subset I, |S|=N} \sum_{i \in S} \hat{f}(u, i)$$


Список — на будущее!!

Виды рекомендаций

Не единственная как минимум потому, что можно не только пользователям айтемы рекомендовать 😊

С точки зрения алгоритма (на каких данных обучается) либо с точки зрения объектов-субъектов рекомендаций можно выделить U2I, I2I, U2U

Почему важно различать: алгоритм для I2I-полки вполне может обучаться на U2I-данных



Каскадный пайплайн




Этапов – много, но сейчас есть тренд на создание end2end-систем, инкапсулирующих в себе логику целого пайплайна

From PML-2026

Шакально, потому что
запись еще не выложили

itmo



А как решать?

Конкретные методы будем
разбирать дальше в течение курса

ITMO

Подход	Обучающий пример	Типичная ситуация
Regression	$(u, i) \rightarrow y_{ui}$, где $y_{ui} \in \mathbb{R}$ (рейтинг, время просмотра)	Есть явные оценки пользователей: рейтинги фильмов (1–5), время просмотра видео, сумма покупки
Classification	$(u, i) \rightarrow y_{ui}$, где $y_{ui} \in \{0, 1\}$ (клик/не клик, покупка/нет)	Прогноз CTR (клик или нет), предсказание лайка / дизлайка, вероятность конверсии
Point-wise Ranking	$(u, i) \rightarrow \text{score} \in \mathbb{R}$ (сводим к регрессии/классификации)	Большой каталог, нужно быстро посчитать скор для всех i , скорость важнее точности порядка
Pair-wise Ranking	$(u, i, j) \rightarrow i \succ j$ (предмет i релевантнее j)	Есть только факты взаимодействия (клики, покупки), нет оценок. Важен порядок в Top-N, оптимизируем AUC
List-wise Ranking	$(u, \text{список})$ (весь ранжированный список целиком)	Критично качество всей выдачи, нужно максимизировать NDCG@k (поиск, лента новостей, выдача)

На следующих слайдах будет немного больно по причине большого количества формул



Метрики делятся на:

1. Метрики качества – оценивают порядок ранжирования на основе залогированного поведения пользователей
2. Метрики разнообразия – оценивают адекватность рекомендаций «на глаз»

Главное: большинство метрик считаются с отсечкой K (cutoff) – из всего списка рекомендаций берутся первые K штук, и только для них считается метрика

Многие метрики усредняются по пользователям

Никто еще не объяснил метрики лучше, чем Evidently AI:

<https://www.evidentlyai.com/ranking-metrics>

Обозначения

- $u \in \mathcal{U}$ — пользователь, $N = |\mathcal{U}|$ — число пользователей.
- K — глубина списка рекомендаций.
- $R_u^K = (i_{u,1}, \dots, i_{u,L_u})$ — top- K список пользователя u , где $L_u \leq K$.
- $i_{u,r}$ — объект на позиции r .
- $y_{u,r}$ — истинная релевантность объекта; $y_{u,r} > 0$ означает релевантный объект.
- $\mathcal{G}_u$ — множество всех релевантных объектов пользователя u .
- $\mathbf{1}[\cdot]$ — индикатор условия.
- r_u^* — позиция первого релевантного объекта.
- $y_{u,(r)}^*$ — r -я релевантность в идеальном ранжировании.
- $c(i)$ — категориальный признак объекта.
- $\mathbf{e}_i$ — embedding объекта.

Precision@K

$$\text{Precision@K} = \frac{1}{N} \sum_{u \in \mathcal{U}} \frac{\sum_{r=1}^{L_u} \mathbf{1}[y_{u,r} > 0]}{K}$$

Показывает, какая доля из первых K рекомендаций оказалась релевантной.

Recall@K

$$\text{Recall@K} = \frac{1}{N} \sum_{u \in \mathcal{U}} \frac{\sum_{r=1}^{L_u} \mathbf{1}[y_{u,r} > 0]}{|\mathcal{G}_u|}$$

Показывает, какую долю всех релевантных для пользователя объектов система смогла найти в top- K .

MRR@K — Mean Reciprocal Rank

$$\text{MRR@K} = \frac{1}{N} \sum_{u \in \mathcal{U}} \frac{\mathbf{1}[r_u^* \leq K]}{r_u^*}$$

Учитывает позицию первого релевантного объекта: чем выше он находится в списке, тем больше значение метрики.

Hit Rate@K

$$\text{HitRate@K} = \frac{1}{N} \sum_{u \in \mathcal{U}} \mathbf{1} \left[\sum_{r=1}^{L_u} \mathbf{1}[y_{u,r} > 0] > 0 \right]$$

Показывает долю пользователей, у которых в top- K нашёлся хотя бы один релевантный объект. Чем выше, тем лучше.

Метрики качества

DCG@K — Discounted Cumulative Gain



$$\text{DCG@K}(u) = \sum_{r=1}^{L_u} \frac{y_{u,r}}{\log_2(r+1)}$$

Суммирует релевантности с штрафом за низкие позиции: релевантный объект выше в списке ценится сильнее.

IDCG@K — Ideal DCG

$$\text{IDCG@K}(u) = \sum_{r=1}^{\min(K, |\mathcal{G}_u|)} \frac{y_{u,(r)}^*}{\log_2(r+1)}$$

Максимально возможный DCG для пользователя — значение при идеальном порядке объектов.

NDCG@K — Normalized Discounted Cumulative Gain

$$\text{NDCG@K} = \frac{1}{N} \sum_{u \in \mathcal{U}} \frac{\text{DCG@K}(u)}{\text{IDCG@K}(u)}$$

Сравнивает фактический DCG с идеальным. Чем ближе к 1, тем лучше порядок объектов.

Метрики разнообразия



Coverage@K

$$\text{Coverage@K} = \frac{|\bigcup_{u \in \mathcal{U}} R_u^K|}{|\mathcal{I}|}$$

Показывает, какая доля всего каталога $\mathcal{I}$ хотя бы раз попала в top- K рекомендации для пользователей.

Чем выше Coverage@K, тем меньше система концентрируется на небольшом наборе популярных объектов.

Почему не стоит слепо доверять этой метрике (или можно ввести отсечку по частоте) ->



Метрики разнообразия

Interlist Diversity@K

$$\text{Overlap}(u, v) = \frac{|R_u^K \cap R_v^K|}{\min(|R_u^K|, |R_v^K|)}$$

$$\text{InterlistDiversity@K} = 1 - \frac{2}{N(N-1)} \sum_{u < v} \text{Overlap}(u, v)$$

Измеряет, насколько различаются рекомендации разных пользователей. Выше — меньше пересечений между списками.

Еще есть Novelty и Serendipity, но никто не знает, как их правильно считать

Intralist Similarity@K

$$\text{ILS@K}(u) = \frac{2}{L_u(L_u - 1)} \sum_{1 \leq a < b \leq L_u} \cos(\mathbf{e}_{i_{u,a}}, \mathbf{e}_{i_{u,b}})$$

$$\cos(\mathbf{e}_i, \mathbf{e}_j) = \frac{\mathbf{e}_i^\top \mathbf{e}_j}{\|\mathbf{e}_i\|_2 \|\mathbf{e}_j\|_2}$$

$$\text{ILS@K} = \frac{1}{N} \sum_{u \in \mathcal{U}} \text{ILS@K}(u)$$

Здесь $\text{ILS@K}(u)$ — средняя попарная cosine similarity объектов внутри списка пользователя u .

Если similarity находится в $[0, 1]$, diversity можно записать как:

$$\text{ILD@K} = 1 - \text{ILS@K}$$

Измеряет, насколько объекты внутри одного списка похожи друг на друга. Ниже ILS — выше разнообразие.

Предобработка


іТМО

- Фильтрация по рейтингу / типу событий
- k-core фильтрация
- Фильтрация холодных юзеров / айтемов



Проблема – итеративность

Train-val test Splitting



Бейзлайны

Зачем они сервису?

- Холодный старт
- Fallback
- «Вечный контроль»

Зачем они вам?

- Сравниться с простой моделью по качеству
- Оценить, насколько рекомендации модели отличаются. Например, генеративные модели могут страдать от bias-а в сторону популярных айтемов



daisyRec


Fair Comparison for RecSys

Modules

Components

Attributes

Functions



Бейзлайны.

Worst & Random & Best

ITMO

Worst – не всегда нулевая метрика!
Нижняя граница качества модели

Два вида Random:

1. Случайно выбираем K рекомендаций, рекомендуем их всем
2. Случайно выбираем K рекомендаций для каждого пользователя. Свойство – высокий Coverage

Best – не всегда единичная метрика!
Верхняя граница качества модели

■ Variation A

10.03%



■ Variation B

10.07%



Бейзлайны. TopPopular & TopPersonal

ITMO

Самые сильные бейзлайны

TopPopular:

1. Выбираем К самых популярных айтемов, рекомендуем их всем
2. Считаем популярность каждого айтема из каталога, нормируем, для каждого пользователя сэмплируем с вероятностями

100500 вариаций:

- RecentPop (Trending)
- DecayPop
- SocdemTopPopular

TopPersonal >> TopPopular в FMCG (задумайтесь, как часто вы покупаете одни и те же продукты)

список




250 лучших фильмов

250 фильмов



500 лучших фильмов

500 фильмов



Популярные фильмы

1000 фильмов

Спасибо за внимание!

itMO *re than a*
UNIVERSITY

334743@niuitmo.ru