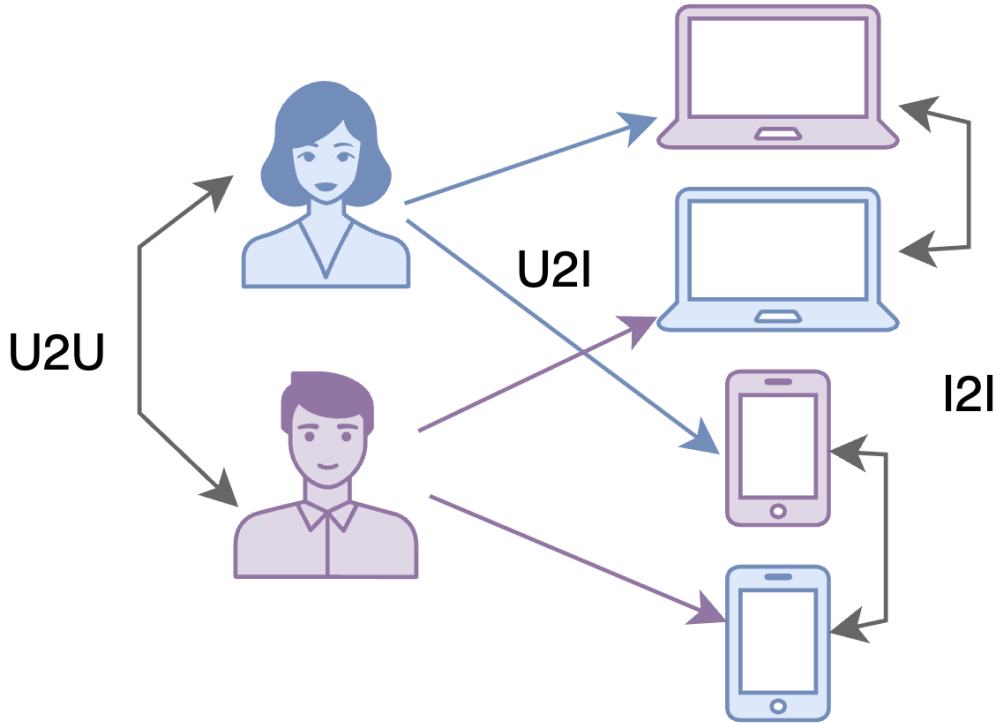
ITMO

I2I и U2U рекомендации

Еще раз о задачах



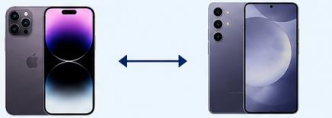
ITMO

I2I

Тип связи между товарами

Похожие товары
(Substitutes)

Товары, которые выполняют одинаковую или очень схожую функцию и могут заменять друг друга.



iPhone 15 — Samsung Galaxy S24



Nike Air Force 1 — Adidas Stan Smith



MacBook Air — Dell XPS

Примеры сценариев:

- разные бренды с похожими характеристиками
- разные модели одной категории
- товары-конкуренты

Комплементарные товары
(Complements)

Товары, которые часто используются вместе и дополняют друг друга.



Фотоаппарат — Карта памяти



PlayStation 5 — Дополнительный геймпад



Смартфон — Чехол

Примеры сценариев:

- основной товар и аксессуары
- товар и расходные материалы
- товары, которые используются вместе для достижения одной цели

Тематические товары
(Same Category / Thematic)

Товары, которые относятся к одной тематической категории или удовлетворяют одну и ту же потребность, но не обязательно заменяют или дополняют друг друга.

Товары для путешествий



Чемодан — Подушка для путешествий — Рюкзак — Органайзер для документов

Товары для готовки



Сковорода — Кастрюля — Лопатка — Разделочная доска

Товары для спорта



Коврик для йоги — Бутылка для воды — Гантели — Фитнес-резинка

Примеры сценариев:

- товары из одной категории
- товары для одного вида деятельности
- товары, удовлетворяющие одну потребность
- стилистически или тематически близкие товары

Бизнес-стратегия

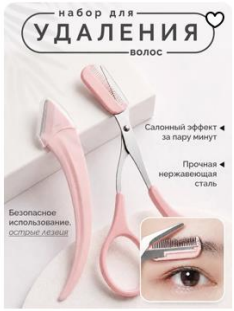
- **Upsell** – предложение более дорогой или функциональной версии товара, чтобы увеличить средний чек
- **Cross-sell** – предложение дополняющих товаров, чтобы расширить корзину
- **Downsell** – предложение более дешёвой альтернативы, чтобы сохранить конверсию
- **Bundling** – объединение нескольких товаров в набор, чтобы увеличить объём покупки



Рекомендуем также







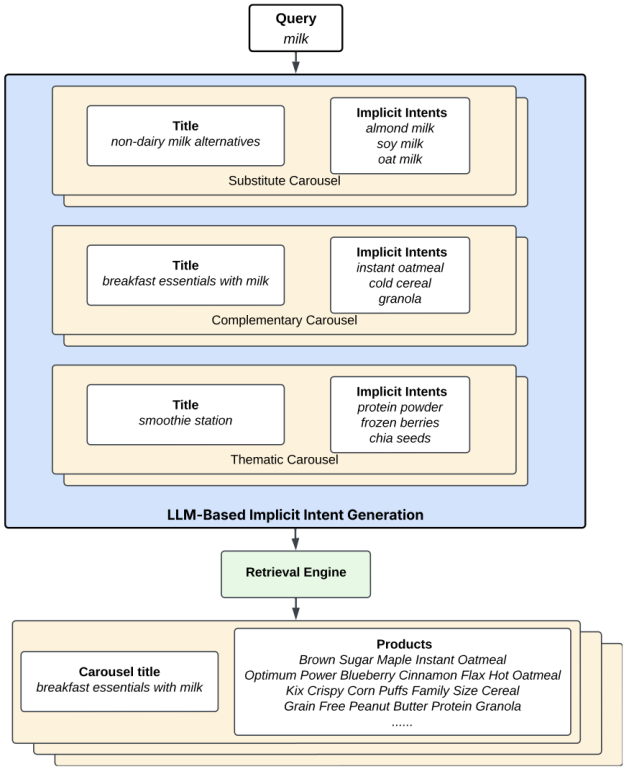


Как решать?

1. Representation Learning на контенте
   Риски: однообразные рекомендации без бизнес-контекста

2. Перенос знаний из U2I в I2I
   Риски: «почему к соли для ванны рекомендуется чесалка для спины?»

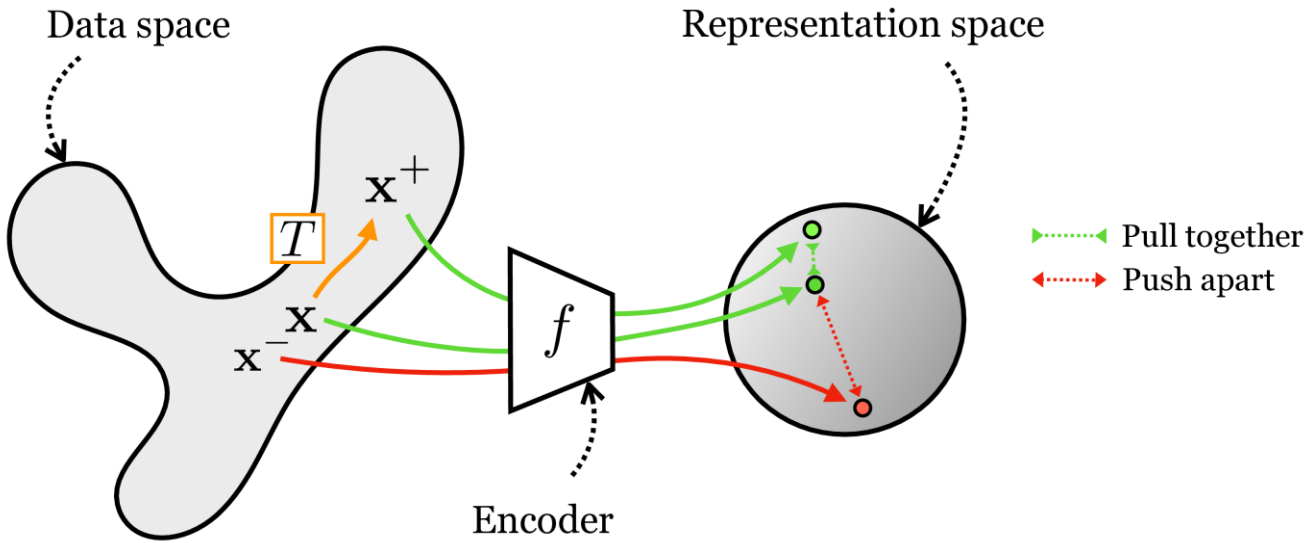
3. Совмещение этих стратегий
   Риски: сложное и дорогое обучение



Improving Item Discoverability in e-Commerce Search via Related Intent Generation

Representation Learning

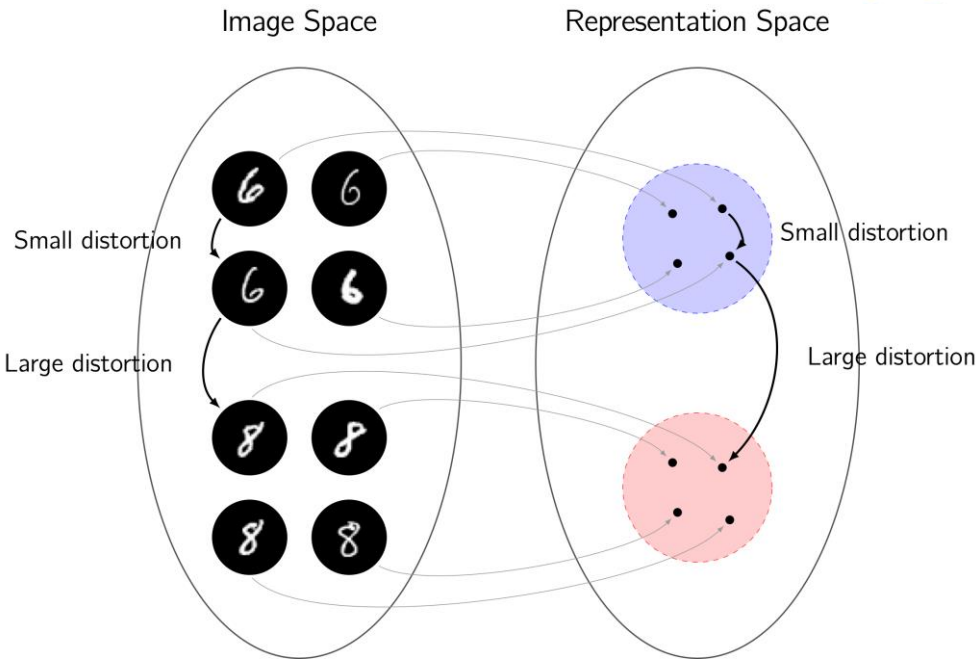
С помощью контрастивной функции потерь формируем пространство эмбеддингов.
Обычно требуется размеченная выборка. За функцию сходства часто берется dot product



Representation Learning. Оценка

Качество получаемых эмбеддингов можно оценить:

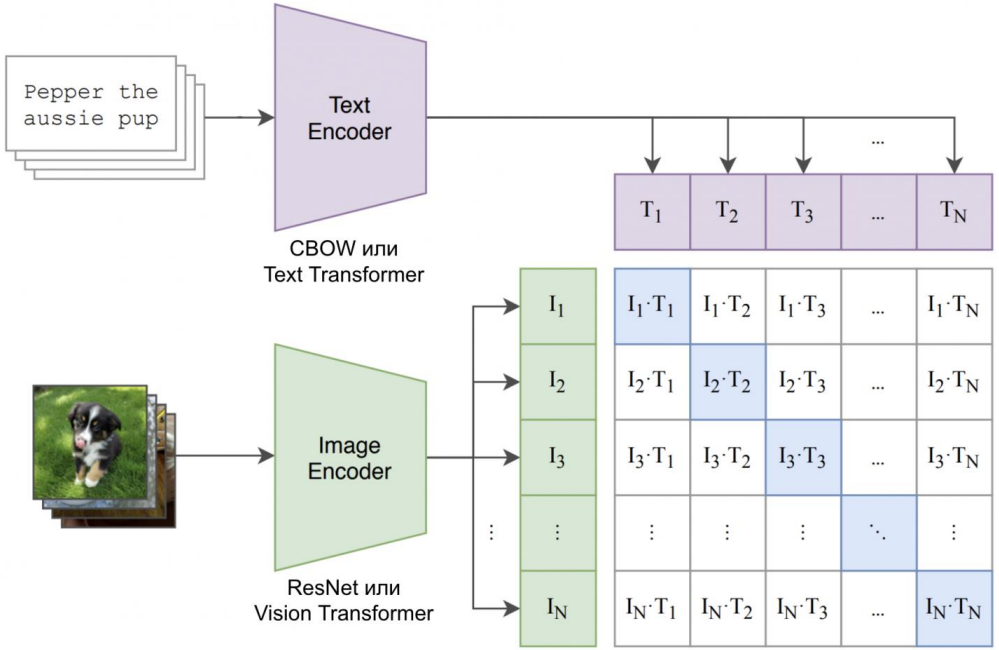
- С помощью специализированных бенчмарков
- с помощью кластеризации = насколько хорошо фрагментируется пространство
- за счет прокси-задачи (например, классификация по категориям)
- сразу встраивая в целевую задачу, но это обычно нереалистичный сценарий



Хабр: ruSciBench — бенчмарк для оценки эмбеддингов научных текстов

Предобученные модели

- **Text:** Qwen3-Embedding, BGE-M3, EmbeddingGemma
- **Image:** DINOv3
- **Audio:** CLAP, MERT
- **Video:** V-JEPA 2, VideoPrism
- **Multimodal:** SigLIP 2, Jina Embeddings v4, CLIP (классика)



U2I -> I2I

Совстречаемость: совместные покупки (подумайте, почему не подойдут совместные просмотры)

Поисковые логи! – можем считать похожими айтемы, на которые разные юзеры кликали по одинаковому запросу

Простая модель: PMI (Pointwise Mutual Information) – мера того, насколько два товара встречаются вместе чаще, чем ожидалось бы случайно с учетом их популярности

- PMI > 0 – товары связаны сильнее случайного ожидания
- PMI ≈ 0 – почти независимы
- PMI < 0 – встречаются вместе реже ожидаемого

$$PMI(i,j) = \log \frac{P(i,j)}{P(i)P(j)}$$

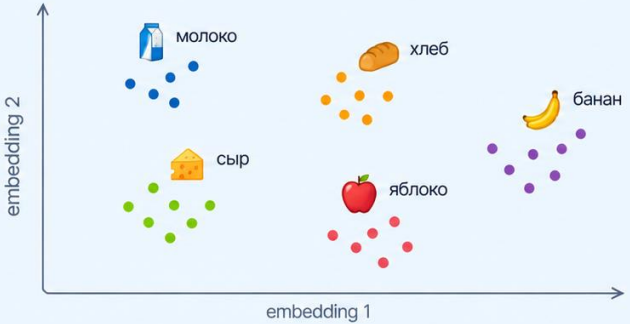
Плюс: снижает влияние очень популярных товаров
Минус: может сильно завышать связь редких пар

Item2vec vs EASE

Модели учатся на одинаковых данных, но результат – разный!

Item2Vec

- Учит плотные векторы товаров с помощью skip-gram (предсказывает товары в контексте корзины).
- Схватывает сложные и дальние связи между товарами.
- **Результат:** по запросу товара ищем ближайшие по косинусному сходству в embedding-пространстве.



Пример данных: набор корзин

Пользователь 1	
Пользователь 2	
Пользователь 3	
Пользователь 4	
...	...

EASE

- Строит линейную модель на матрице «товар–товар», находя веса, которые хорошо восстанавливают корзины пользователей.
- Учитывает прямые попарные связи и автоматически убирает влияние очень популярных товаров.
- **Результат:** для каждого товара есть веса к другим товарам, по которым формируются рекомендации.

	молоко	хлеб	сыр	банан	яблоко
молоко	–	0.42	0.28	0.20	0.05
хлеб	0.39	–	0.35	0.18	0.08
сыр	0.25	0.33	–	0.05	0.12
банан	0.17	0.16	0.04	–	0.29
яблоко	0.06	0.09	0.11	0.31	–

Swing

Это I2I-алгоритм на user-item графе, который усиливает связь между товарами, если несколько независимых пар пользователей взаимодействовали с обоими товарами

$$s(i,j) = \sum_{u \in U_i \bigcap U_j} \sum_{v \in U_i \bigcap U_j} w_u \cdot w_v \cdot \frac{1}{\alpha + |I_u \bigcap I_v|}$$

where

$$w_u = \frac{1}{\sqrt{|I_u|}}, w_v = \frac{1}{\sqrt{|I_v|}}$$

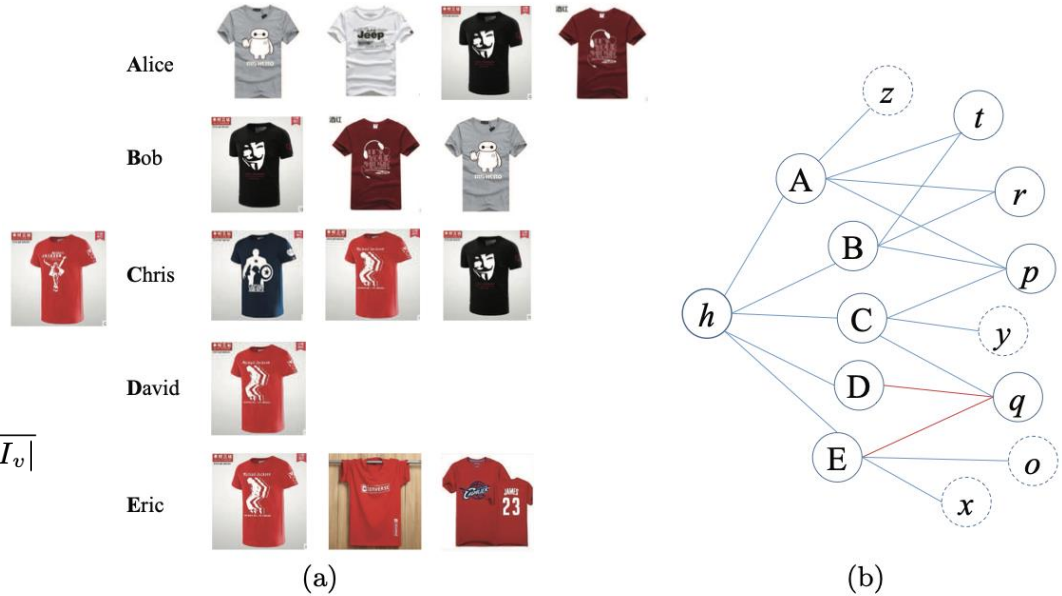
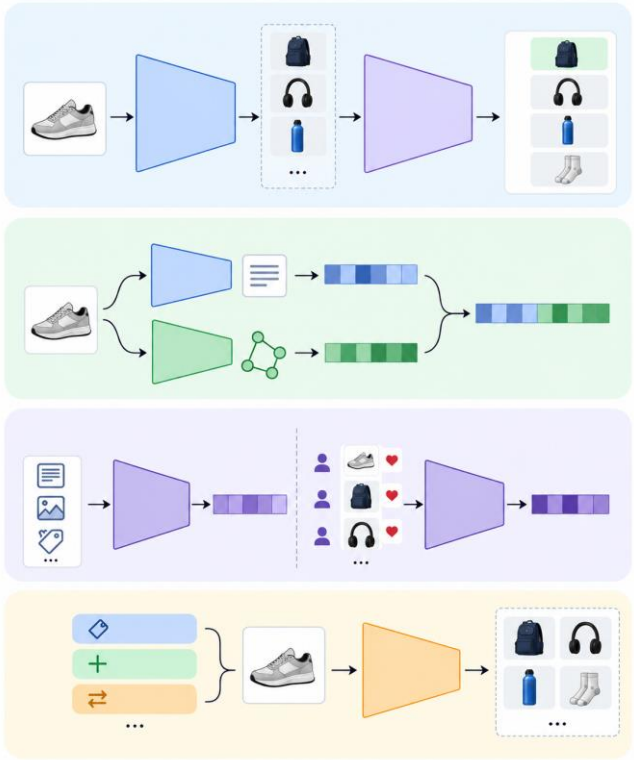


Figure 2: An Example of Swing score computing.

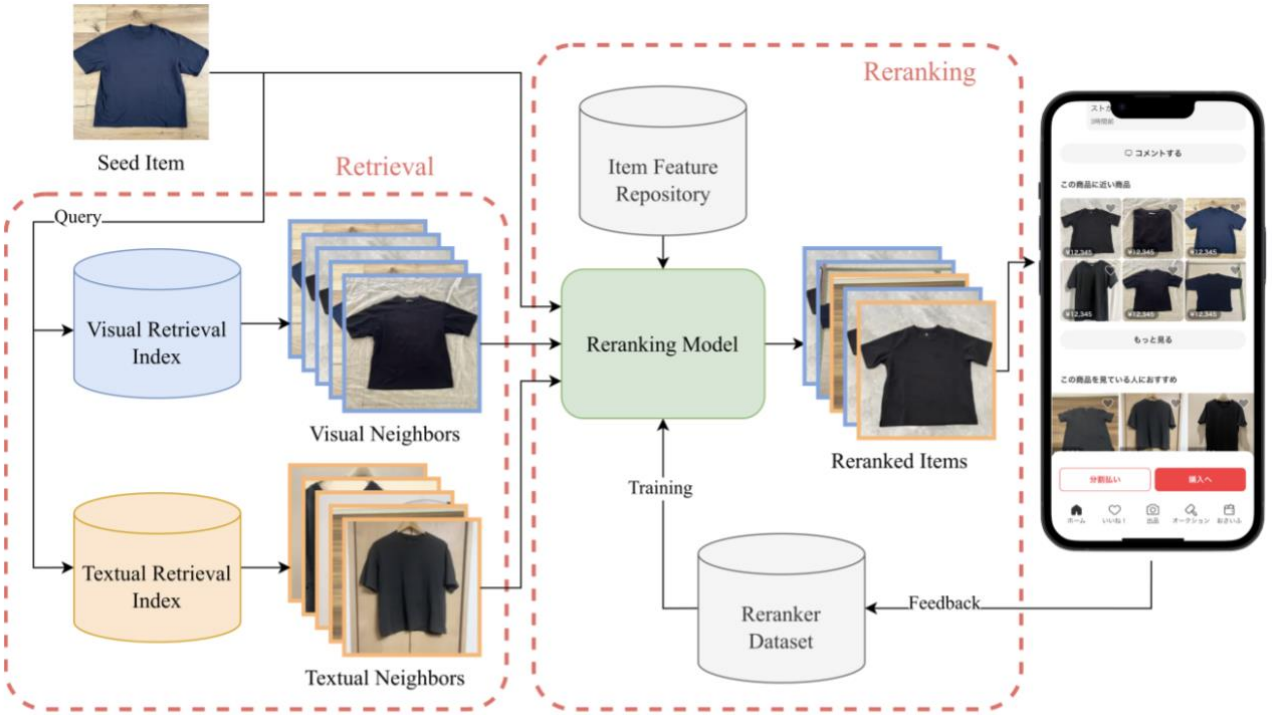
Large Scale Product Graph Construction for Recommendation in E-commerce

Гибридная стратегия

1. Retrieval на контенте -> Ranking на коллаборативной информации
2. Смешиваем контентный и коллаборативный сигналы при обучении модели (например, за счет взвешенной суммы двух контрастивных лоссов)
3. Учим модель на контенте, дообучаем на коллаборативной информации
4. Учим генеративку с control-токенами, которые задают то, связь какого типа мы сейчас пытаемся сгенерировать



Каскадный i2i



Hybrid Retrieval and Multimodal Reranking for Item-to-Item Recommendation in a C2C Marketplace

PI2I

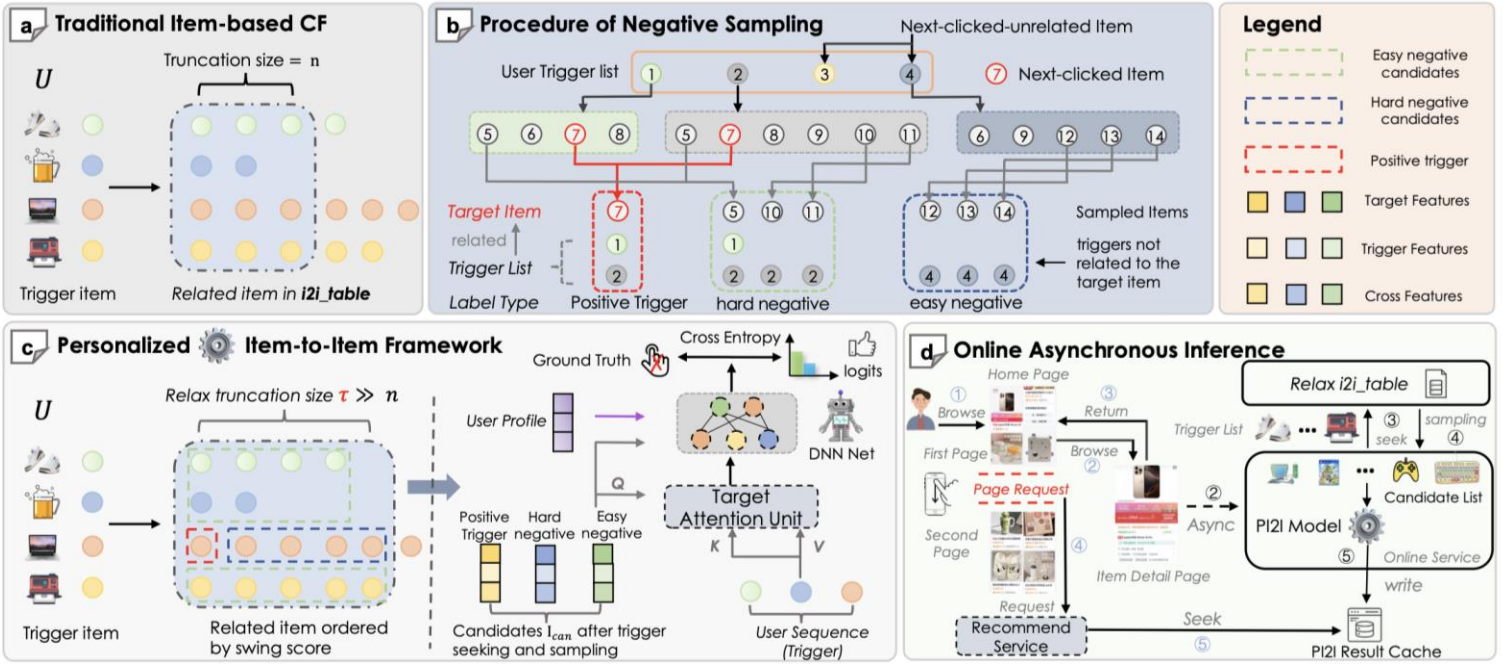


Figure 2: (a) Illustration of traditional I2I methods. (b) Illustration of the trigger-target sampling strategy. (c) The overall framework of PI2I. (d) Procedure of the PI2I Online Asynchronous Inference.

PI2I: A Personalized Item-Based Collaborative Filtering Retrieval Framework

IIMRec

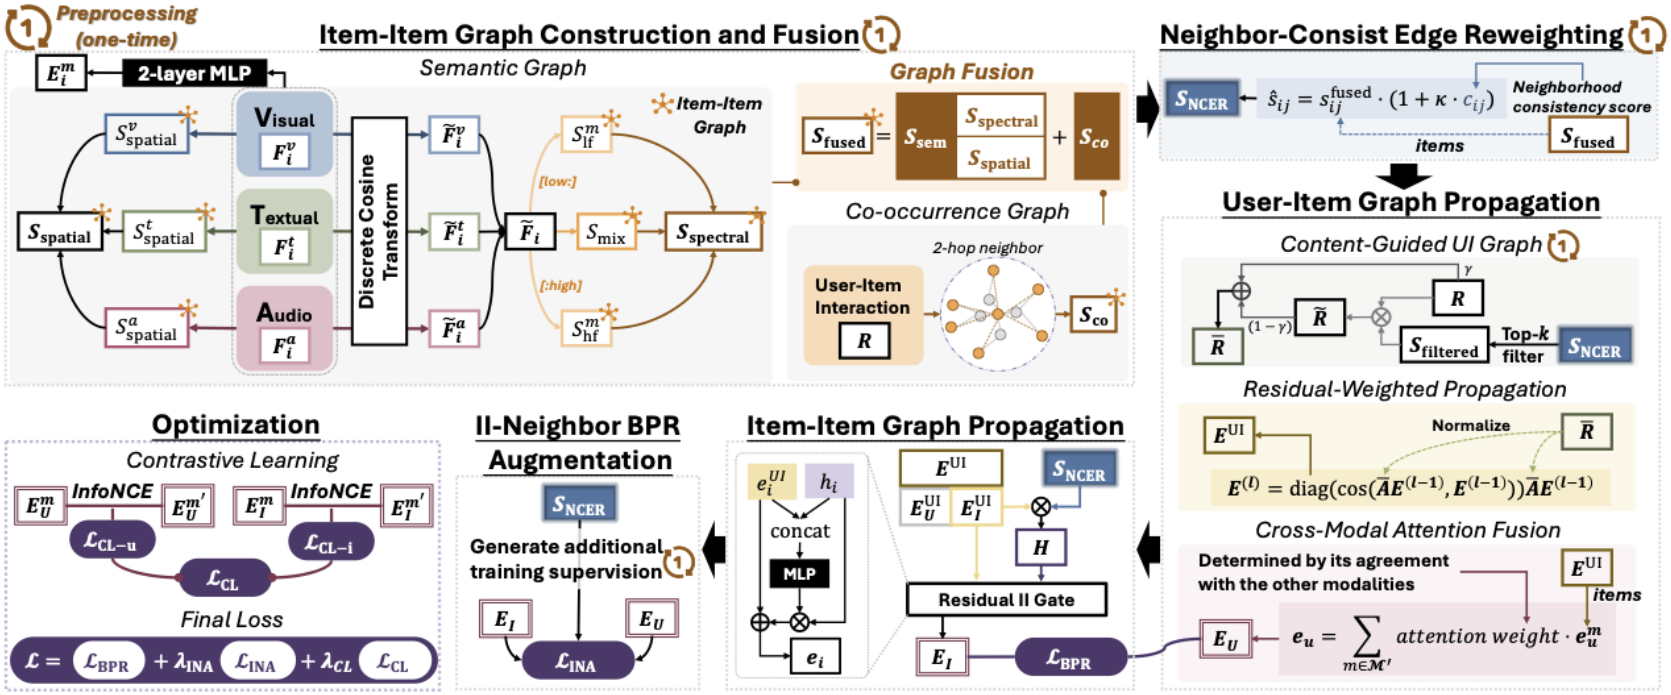


Figure 1: The overall structure of IIMRec.

One Graph, Multiple Gains: Single High-Quality Item-Item Graph for Multimodal Recommendation

ITMO

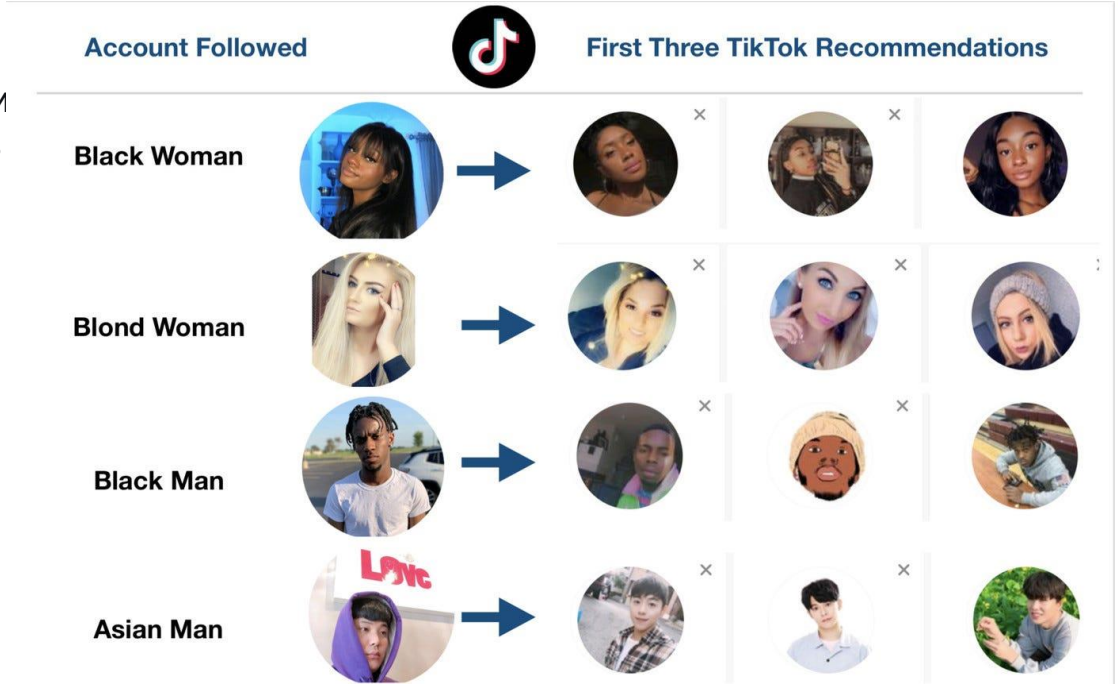
U2U

Зачем?

Для пользователя – рекомендации друзей; рекомендации криэйторов

Для бизнеса – lookalike-и. Поиск пользователей, похожих на уже известную «ценную» аудиторию

Просто хорошие эмбеддинги пользователей, которые можно встроить в любую downstream-задачу



Связь между пользователям

Behavioral similarity

Покупают / смотрят / слушают одинаковое.



- Покупки одних товаров
- Просмотры одинакового контента
- Лайки / реакции
- Похожие поисковые запросы

Interest similarity

Интересуются одними темами, даже если конкретные объекты разные.



- Похожие категории контента / товаров
- Схожие тематики в профиле
- Похожие сообщества и подписки
- Схожие ценности и предпочтения

Social proximity

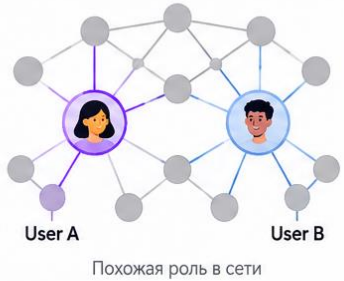
Близки в социальном графе: общие друзья, подписки, сообщества.



- Общие друзья
- Взаимные подписки
- Общие группы / сообщества
- Частые взаимодействия (комментарии, сообщения)

Structural similarity

Занимают похожее положение в графе, даже если напрямую не связаны.



- Похожая центральность (например, число связей)
- Сходная позиция в сообществе
- Похожие паттерны связей
- Сходная роль (например, «криэйтор», «активный участник»)

Поведенческие эмбеддинги

- Hidden state из двухбашенных U2I-моделей
- Специализированные контрастивные модели для User Representation Learning

RecSys Challenge 2025

The challenge is designed to promote a unified approach to behavior modeling. Many modern enterprises rely on machine learning and predictive analytics for improved business decisions. Common predictive tasks in such organizations include recommendation, propensity prediction, churn prediction, user lifetime value prediction, and many others. A central piece of information that is used for these predictive tasks are logs of past behavior of users e.g., what they bought, what they added to their shopping cart, which pages they visited. Rather than treating these tasks as separate problems, we propose a unified modeling approach.

To achieve this, we introduce the concept of Universal Behavioral Profiles—user representations that encode essential aspects of each individual's past interactions. These profiles are designed to be universally applicable across multiple predictive tasks, such as churn prediction and product recommendations. By developing representations that capture fundamental patterns in user behavior, we enable models to generalize effectively across different applications.

Поведенческие эмбеддинги. CoLES

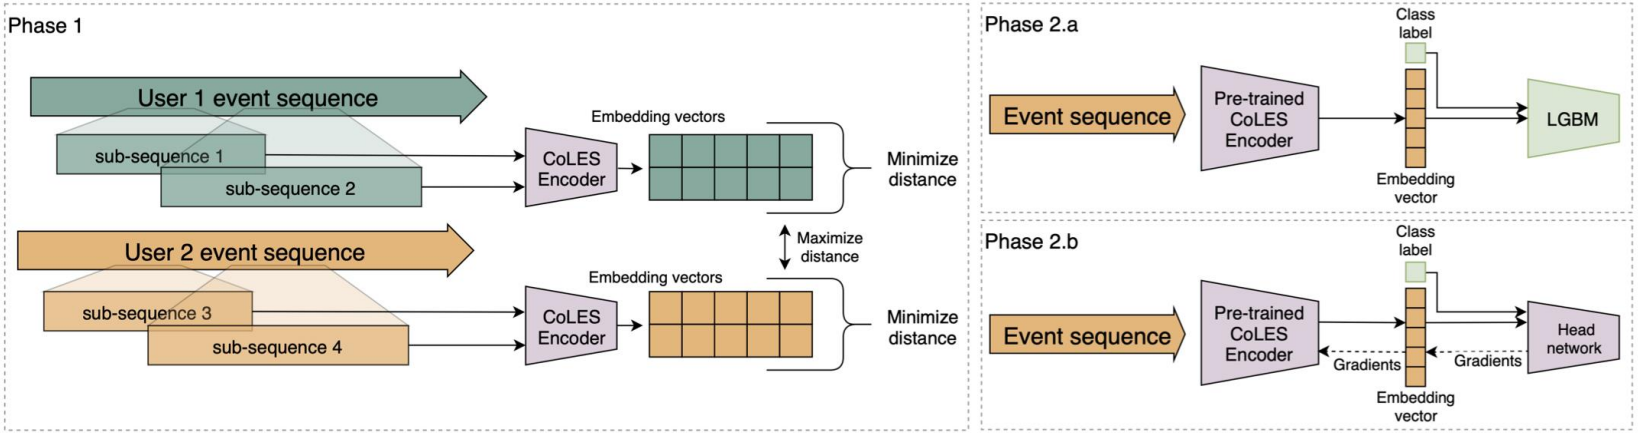
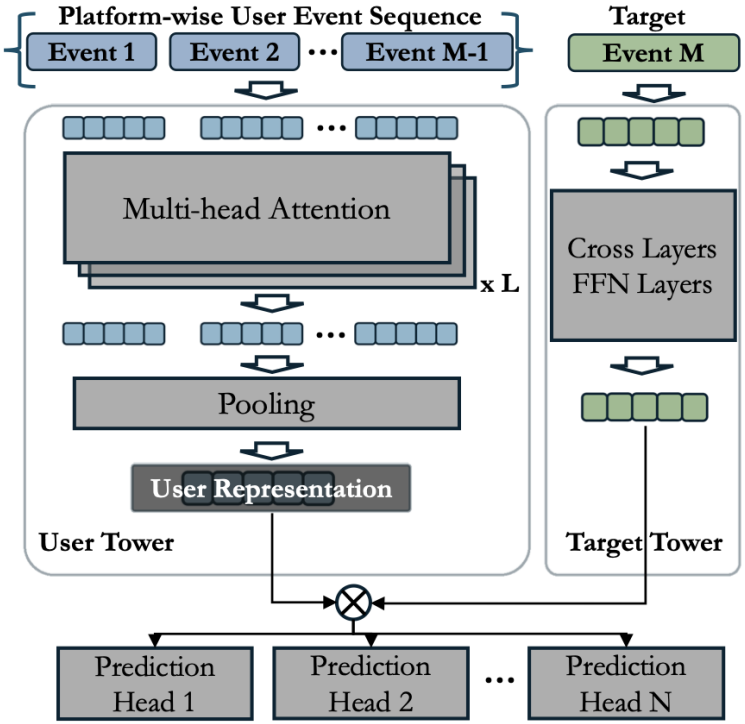
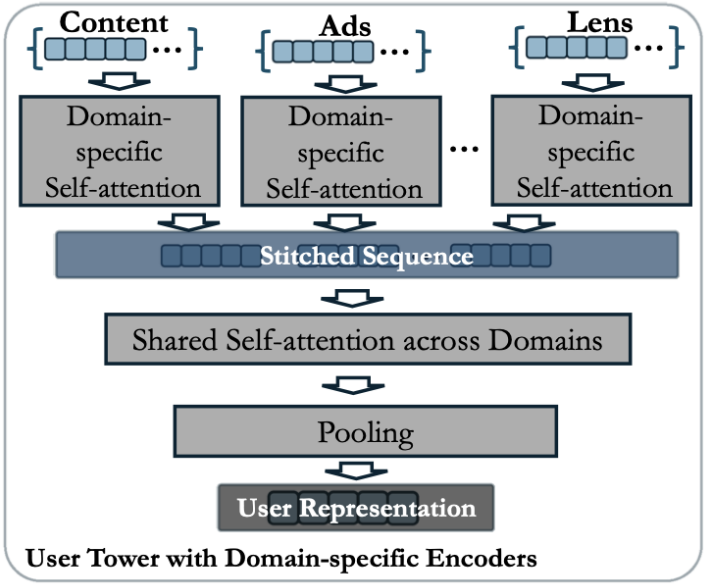


Figure 1: General framework. Phase 1: Self-supervised training. Phase 2.a Self-supervised embeddings as features for supevised model. Phase 2.b: Pre-trained encoder fine-tuning.

CoLES: Contrastive Learning for Event Sequences with Self-Supervision

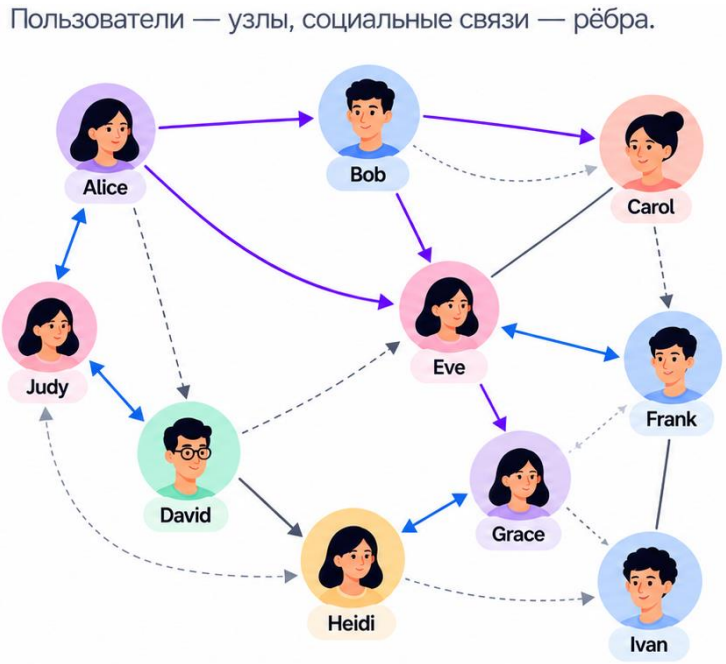
Поведенческие эмбеддинги. UUM





Learning Universal User Representations Leveraging Cross-domain User Intent at Snapchat

Социальный граф



Основные элементы

Узел (node)
пользователь
- профиль
- интересы
- активность
- эмбеддинг
- дополнительные атрибуты (возраст, пол, гео и т.п.)

Ребро (edge)
социальная связь
- тип связи (подписка, дружба и т.п.)
- направление
- вес (частота взаимодействий, близость и т.п.)

Типы связей (пример)

Подписка (follow)
направленная связь

Дружба (friendship)
взаимная связь

Взаимодействие
лайк, комментарий, сообщение и т.п.

Общая группа / сообщество
пользователи состоят в одной группе

Слабая связь
редкие взаимодействия

Примеры атрибутов узлов
- профиль (возраст, пол, гео)
- интересы / темы
- активность (количество постов, лайков и т.п.)
- эмбеддинг пользователя
- роль (криэйтор, модератор и т.п.)

Примеры атрибутов рёбер
- тип связи (follow, like, comment, message и т.п.)
- вес (частота взаимодействий)
- время последнего взаимодействия
- контекст (в каком сообществе)
- направление (если связь не взаимная)

Кстати, транзакционный граф – тоже разновидность социального графа

Структуры в социальном графе

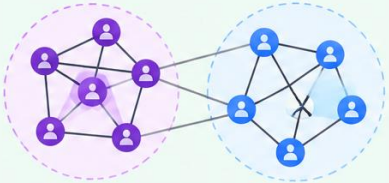
Hubs (хабы)

Узлы с большим числом связей. Часто это популярные пользователи, криэйторы, медиа.



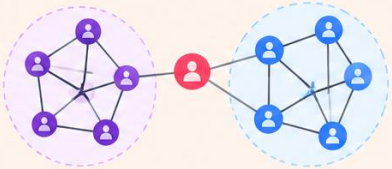
Communities (сообщества)

Группы пользователей, которые плотнее связаны внутри группы, чем снаружи.



Bridges (мосты)

Пользователи, которые соединяют разные сообщества. Часто имеют высокую betweenness centrality.



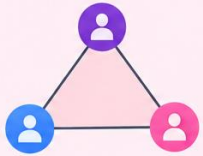
Components (компоненты)

Независимые части графа, между которыми нет связей. В соцсетях обычно есть одна большая компонента и много маленьких.



Triangles / clustering (треугольники / кластеризация)

Друзья часто связаны между собой. Высокая локальная кластеризация означает много треугольников.



Structural roles (структурные роли)

Пользователи могут занимать похожие роли в графе, даже если находятся в разных частях сети: хаб, мост, лидер сообщества, периферийный пользователь и т.п.



Напоминание:

Degree – количество рёбер, связанных с узлом

Betweenness centrality – мера того, как часто узел лежит на кратчайших путях между другими узлами

Алгоритмы на локальном сходстве

Идея: два пользователя похожи, если у них пересекается локальное окружение
Пусть N(u) – множество соседей юзера u

1. Ближайшие соседи $score(u, v) = |N(u) \cap N(v)|$

2. Jaccard Similarity $score(u, v) = \frac{|N(u) \cap N(v)|}{|N(u) \cup N(v)|}$

3. Adamic-Adar (редкий общий сосед важнее хаба) $score(u, v) = \sum_{z \in N(u) \cap N(v)} \frac{1}{\log |N(z)|}$

Personalized PageRank

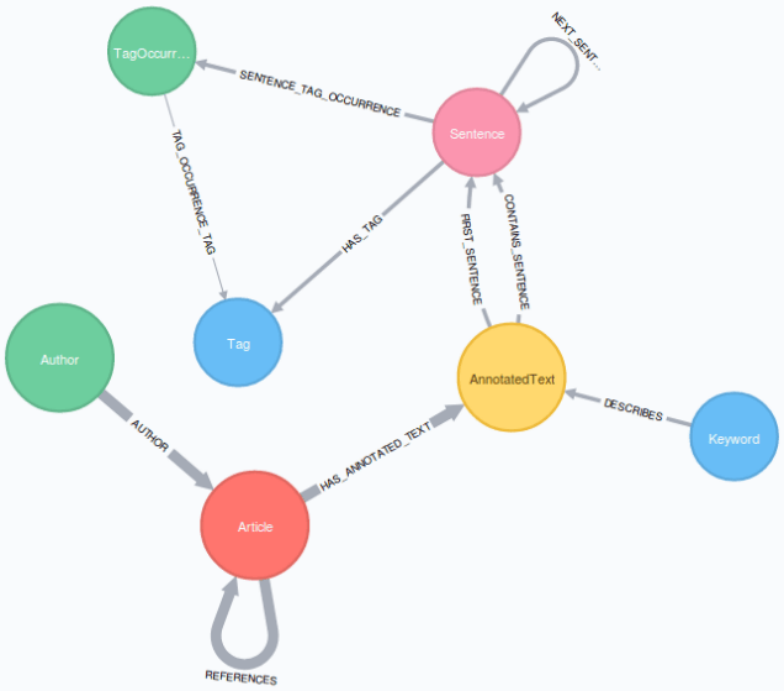
Идея: учитывать не только непосредственных соседей, но и все пути по графу, при этом отдавая больший вес близким узлам

Запускаем random walk из пользователя u:

- с вероятностью 1-a идём к случайному соседу
- с вероятностью a возвращаемся в u

$$p_{t+1} = (1 - \alpha)P^{\top}p_t + \alpha e_u$$

$$score(u, v) = p_v$$



Article recommendation system on a citation network using Personalized Pagerank and Neo4j

Node2Vec

Идея: превратить граф в последовательности узлов и применить Representation Learning

$$Graph \rightarrow Random\ Walks \rightarrow Node\ Sequences \rightarrow Word2Vec \rightarrow Embeddings$$

Random walk $P(v_{t+1} = x \mid v_t = v) \propto w_{vx}$

В Node2Vec переход дополнительно зависит от предыдущего шага $P(x \mid v, t) \propto \alpha_{pq}(t, x) \cdot w_{vx}$

Параметры p и q управляют характером обхода:

- ближе к BFS -> ищем пользователей из того же сообщества
- ближе к DFS -> ищем похожие structural roles

GNN

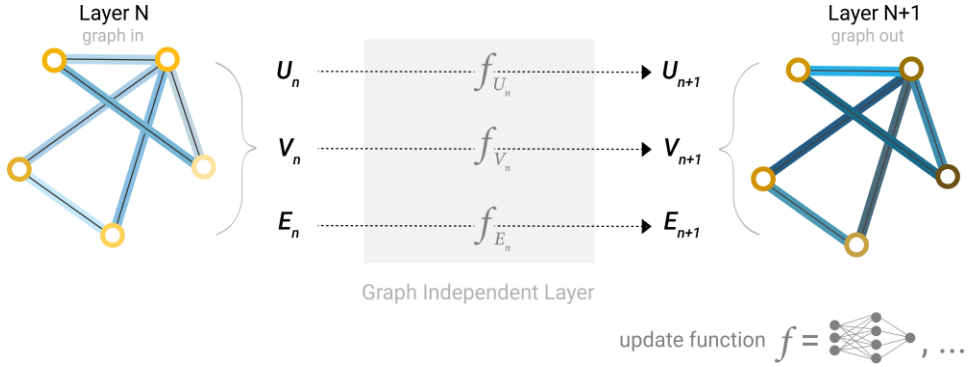
Идея: зачем генерировать random walks, если можно учить representation непосредственно из соседей графа?

Общий принцип message passing:

$$h_u^{(l+1)} = AGGREGATE\left(\{h_v^{(l)} : v \in N(u)\}\right)$$

Каждый слой расширяет receptive field

Многие GNN основываются на идее GCN (Graph Convolution Networks)



A Gentle Introduction to Graph Neural Networks

GNN. GraphSage

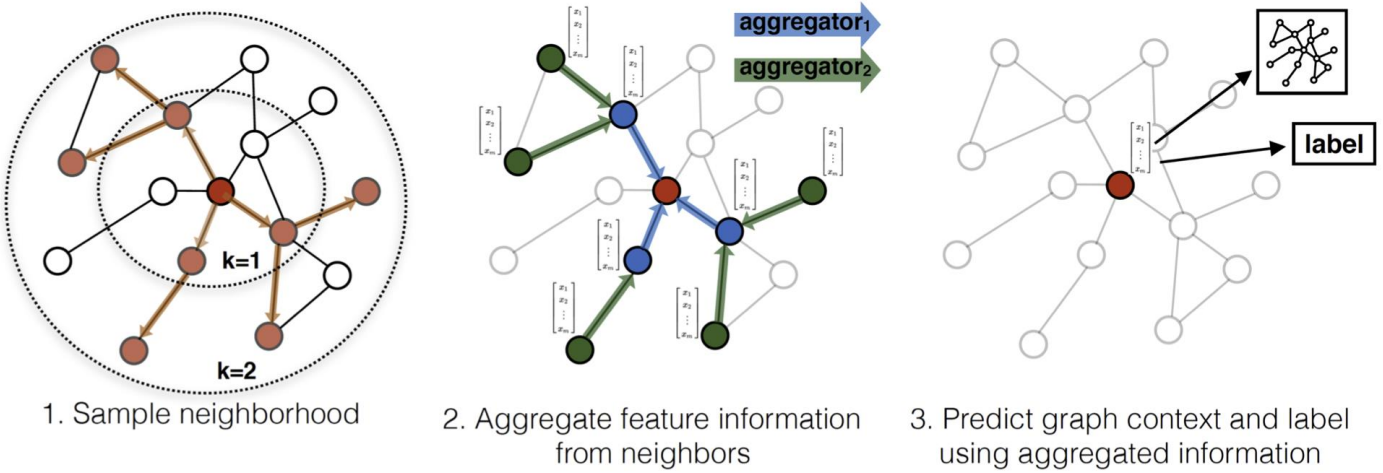


Figure 1: Visual illustration of the GraphSAGE sample and aggregate approach.

Inductive Representation Learning on Large Graphs

GNN. LightGCN

Идея: для рекомендаций классический GCN можно упростить
LightGCN убирает нелинейные активации и преобразования фичей

Для пользователя: $e_u^{(k+1)} = \sum_{i \in N(u)} \frac{1}{\sqrt{|N(u)||N(i)|}} e_i^{(k)}$

Для айтема: $e_i^{(k+1)} = \sum_{u \in N(i)} \frac{1}{\sqrt{|N(i)||N(u)|}} e_u^{(k)}$

Финальный эмбеддинг объединяет несколько слоев:

$$e_u = \sum_{k=0}^{K} \alpha_k e_u^{(k)} \qquad \hat{y}_{ui} = e_u^\top e_i$$

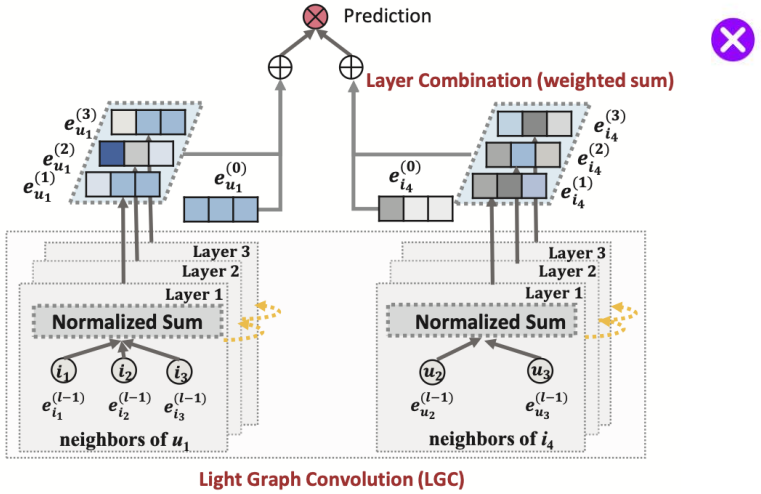


Figure 2: An illustration of LightGCN model architecture. In LGC, only the normalized sum of neighbor embeddings is performed towards next layer; other operations like self-connection, feature transformation, and nonlinear activation are all removed, which largely simplifies GCNs. In Layer Combination, we sum over the embeddings at each layer to obtain the final representations.

LightGCN: Simplifying and Powering Graph Convolution Network for Recommendation

Спасибо за внимание!

ITMO more than a UNIVERSITY

334743@niuitmo.ru